עיבוד אותות - פרויקט 2

קישור למחברת בקולאב

חלק 1: *Loading and Visualizing the EEG Signal*

2. ניצור וקטור זמן באורך 40 שניות (החל משנייה 0), מתוך תדר הדגימה של הניסוי (1024Hz). נקבל בסך הכל 40,960 דגימות.

```
# Variables for sampling frequency, a time vector, and a time window.
fs = 1024
t = np.arange(0, 40, 1/fs)
window_3s = int(3 * fs)

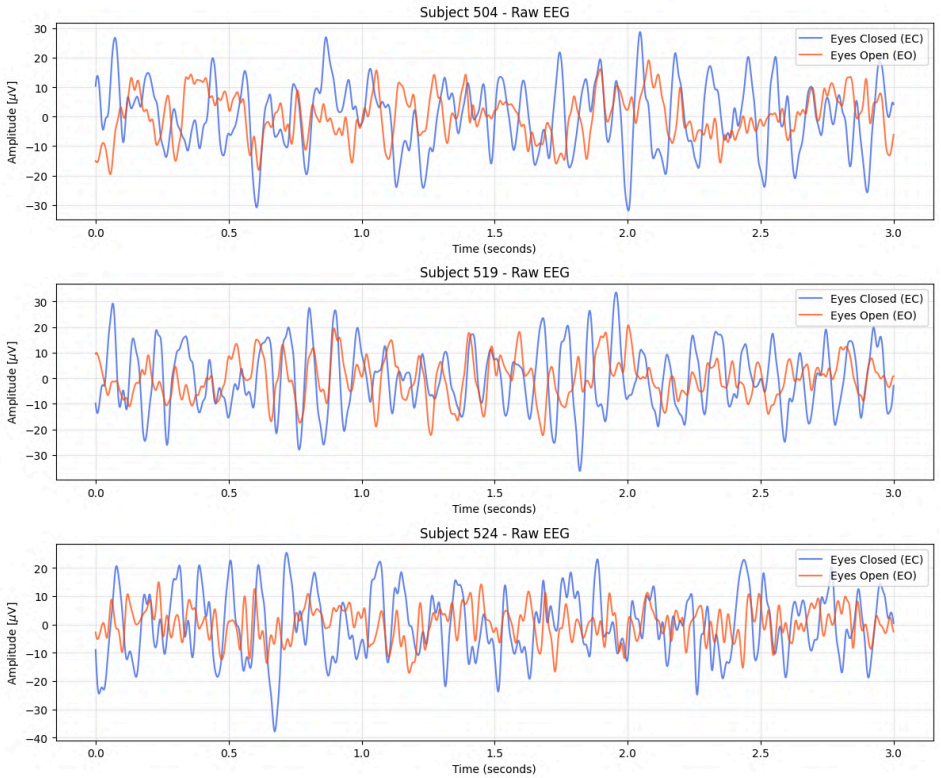
# List of subjects.
subjects = ['504', '519', '524']
data = {}

# A loop to load and extract data for each participant.
for sub in subjects:
  file_path = f'/content/drive/MyDrive/Signal Processing/Project #2/subject_{sub}.csv'
  df = pd.read_csv(file_path)
  data[sub] = {
      'EC': df['EC'].values,
      'EO': df['EO'].values
  }

# Plotting all 3 graphs.
fig, axes = plt.subplots(3, 1, figsize=(12, 10))

for i, sub in enumerate(subjects):
    axes[i].plot(t[:window_3s], data[sub]['EC'][:window_3s], label='Eyes Closed (EC)', color='royalblue', alpha=0.8)
    axes[i].plot(t[:window_3s], data[sub]['EO'][:window_3s], label='Eyes Open (EO)', color='orangered', alpha=0.7)
```

3. עבור כל משתתף יצרתי שתי עקומות אחת על גבי השנייה. אחת מייצגת את המצב של עיניים סגורות, והשנייה מייצגת עיניים פקוחות. בנוסף הגדרתי חלון זמן של 3 שניות מפני שזה מאפשר לנו לראות מספיק מחזורים של גלי אלפא על מנת להבחין בבירור בקצב ובמחזוריות שלהם מבלי לדחוס את הנתונים.



4. נתבונן בגרפים ונשווה בין מצב עיניים עצומות (EC) לבין מצב עיניים פקוחות (EO):

- מצב עיניים עצומות נראה קצבי יותר ממצב עיניים פקוחות.
בגרפים של העיניים העצומות ניתן לראות תבנית מחזורית וסדירה מאוד של עליות וירידות בעלות אמפליטודה יחסית גבוהה. מנגד, בגרפים של העיניים הפקוחות קשה יותר לזהות גל מחזורי ורציף, והאות נראה אקראי יותר.
- ניתן להבחין באופן ברור באוסילציות אלפא במצב של עיניים עצומות. פעילות אלפא מוגדרת בטווח תדרים של 8-12Hz, ואכן אם נספור פיקים במקטע של שנייה אחת בגרפים של העיניים העצומות נגיע בערך ל8-10 פיקים. לעומת זאת, במצב עיניים פקוחות קשה יותר לספור פיקים ברורים ולכן לא ניתן לומר בוודאות שטווח התדרים במצב זה תואם לטווח התדרים של אוסילציות אלפא.

חלק 2: Band-Pass Filtering

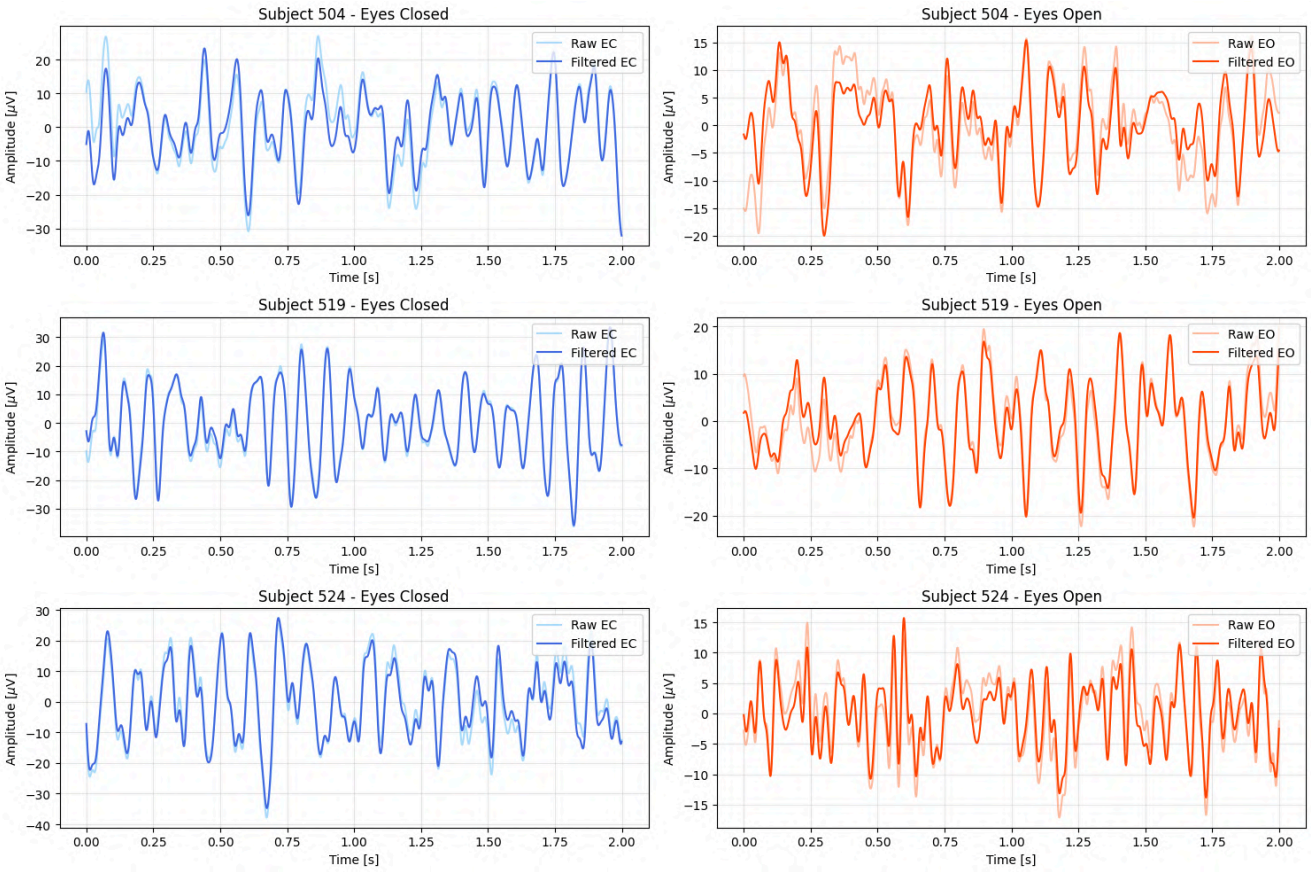
בסעיפים 1-2 הופעל סינון תדרים מסוג Band-Pass, המעביר רק תדרים בטווח 2-40Hz, על נתוני ה-EEG כדי לבודד את הפעילות המוחית הרלוונטית ולסנן רעשי רקע.
תחילה, גבולות התדרים נורמלו ביחס לתדר נייקוויסט, על מנת להפוך את החישוב המתמטי לבלתי תלוי בתדר הדגימה. לאחר מכן, השתמשתי בפילטר מסוג Butterworth מדרגה 4, המאופיין בתגובת תדר המונעת עיוותים בעוצמת האות בטווח הרצוי. הסינון בפועל בוצע באמצעות הפונקציה filtfilt המפעילה את הפילטר פעם אחת קדימה ופעם אחת אחורה בזמן (תהליך שנקרא Zero-Phase Filtering), פעולה קריטית שנועדה לשמור על התזמון המדויק של הפיקים והתנודות באות המקורי.
לבסוף, הגדרתי חלון זמן של שתי שניות (כפי שהתבקשנו).

```
# Calculating low and high limits for the filtering, using nyquist frequency.
nyquist = 0.5 * fs
low = 2 / nyquist
high = 40 / nyquist
b, a = signal.butter(N=4, Wn=[low, high], btype='band')

# Calculating filtering for each subject.
for sub in subjects:
  data[sub]['EC_filtered'] = signal.filtfilt(b, a, data[sub]['EC'])
  data[sub]['EO_filtered'] = signal.filtfilt(b, a, data[sub]['EO'])

# 2-seconds window, according to instructions.
window_2s = int(2 * fs)
```

3. בגרפים הבאים ניתן לראות, עבור כל משתתף וכל מצב, את האות המפולטר (לפי הסינון שהוצג בסעיף הקודם) ביחס לאות המקורי, בחלון זמן של 2 שניות.



חלק 3: *Spectral Analysis and IAF*

<u>חישובים:</u>

1. בסעיף זה יצרתי פונקציה המחשבת את ספקטרום התדרים של האות.
על מנת לעבור ממרחב הזמן למרחב התדר, ולראות אילו תדרים מרכיבים את סיגנל ה-EEG, ביצעתי התמרת פורייה מהירה (FFT) באמצעות הפונקציה np.fft.rfft, אשר מחזירה מערך של מספרים מרוכבים. כדי לקבל את עוצמת האות האמיתית (Power), נרמלתי את התוצאה על ידי חלוקה באורך האות, ולאחר מכן הוצאתי ערך מוחלט כדי להיפטר מהחלק המדומה ולקבל את העוצמה של כל תדר. במקביל, יצרתי את ציר התדרים התואם באמצעות rfftfreq.

```
def power_fft(signal, fs):
  """
  Computes the power spectrum using the Fast Fourier Transform (FFT).
  """
  N = len(signal)
  freqs = np.fft.rfftfreq(N, 1/fs)
  fft_vals = np.fft.rfft(signal)
  normalized_fft = fft_vals / N
  power = np.abs(normalized_fft)
  return freqs, power
```

2. כעת, יצרתי פונקציה שלוקחת את ספקטרום העוצמה שחושב בסעיף הקודם, ומעבירה עליו פילטר החלקה גאוסיאני חד-מימדי עם פרמטר החלקה (סטיית התקן) sigma=3.
בחרתי בהחלקה מסוג זה מפני שהיא משתמשת בשקלולים בצורת פעמון עבור כל נקודה (הנקודות הקרובות אליה ביותר מקבלות א המשקל גבוה ביותר, והמשקל דועך ככל שמתרחקים), כך שהיא מחליקה את הרעשים המקומיים עבור כל נקודה בספקטרום המקורי. הבחירה ב-sigma=3 מאפשרת החלקה עדינה וממוקדת, שמנקה את הרעש האקראי, מבלי לייצר עיוותים או קצוות חדים, ושומרת בצורה אמינה על המיקום של גבעת האלפא.

```
from scipy.ndimage import gaussian_filter1d

def smooth_fft(power, sigma=3):
  """
  Smooths the FFT power spectrum using a moving average filter.
  """
  return gaussian_filter1d(power, sigma=sigma)
```

3. כאן יצרתי פונקציה שמשתמשת בפונקציה המובנית signal.welch. שיטת welch היא טכניקה מתקדמת להערכת צפיפות ספקטרום ההספק (PSD). במקום לחשב FFT פעם אחת על האות השלם, השיטה מחלקת את האות למקטעי זמן קצרים החופפים זה לזה, מחשבת את ספקטרום התדרים עבור כל מקטע בנפרד, ולבסוף ממצעת אותם על מנת לייצר את הגרף הסופי. כך, היא "מבטלת" את הרעש האקראי ומבליטה את הפעילות המחזורית היציבה של הסיגנל, כמו למשל במקרה שלנו- את גלי האלפא. התוצאה היא ספקטרום חלק, יציב ואמין יותר שמקל על זיהוי הפיק האמיתי.
הפרמטרים שבחרתי הם:

- <u>סוג החלון:</u> השתמשתי בחלון מסוג Hann. חלון זה מנמיך את עוצמת האות בקצוות של כל מקטע לאפס. פעולה זו מונעת Spectral Leakage שנוצר כתוצאה מחיתוך פתאומי של האות, ומבטיחה ספקטרום נקי ומדויק יותר.
- <u>אורך החלון:</u> בחרתי באורך חלון של 4 שניות. אורך זה מאפשר פשרה אופטימלית. מצד אחד, החלון ארוך מספיק כדי לספק רזולוציית תדר טובה של 0.25Hz. מצד שני, הוא קצר מספיק ביחס לאות המלא (40 שניות), כך שהוא מאפשר חלוקה למספיק מקטעים לצורך ביצוע ממוצע יעיל.
- <u>חפיפה:</u> השתמשתי בחפיפה של 50% (מיושמת בקוד ע"י חלוקת אורך החלון ב-2). מכיוון שהחלון הנבחר הוא Hann, אשר מאפס את המידע בקצוות של כל מקטע, חפיפה של 50% מבטיחה שהמידע ש"אבד" בקצה של חלון אחד יקבל משקל מלא בחלון הבא. בנוסף, החפיפה מייצרת יותר מקטעים לממוצע הסופי, מה שמקטין את השונות הסטטיסטית ומפיק גרף חלק ונקי מרעשי רקע.

```
def welch_psd(signal_data, fs, win_sec=4, overlap=2):
  """
  Estimates the power spectrum using the Welch method with a 4-seconds window and a 50% overlap.
  """
  nperseg = int(win_sec * fs)
  noverlap = int(nperseg // overlap)
  freqs, psd = signal.welch(signal_data, fs, window='hann', nperseg=nperseg, noverlap=noverlap)
  return freqs, psd
```

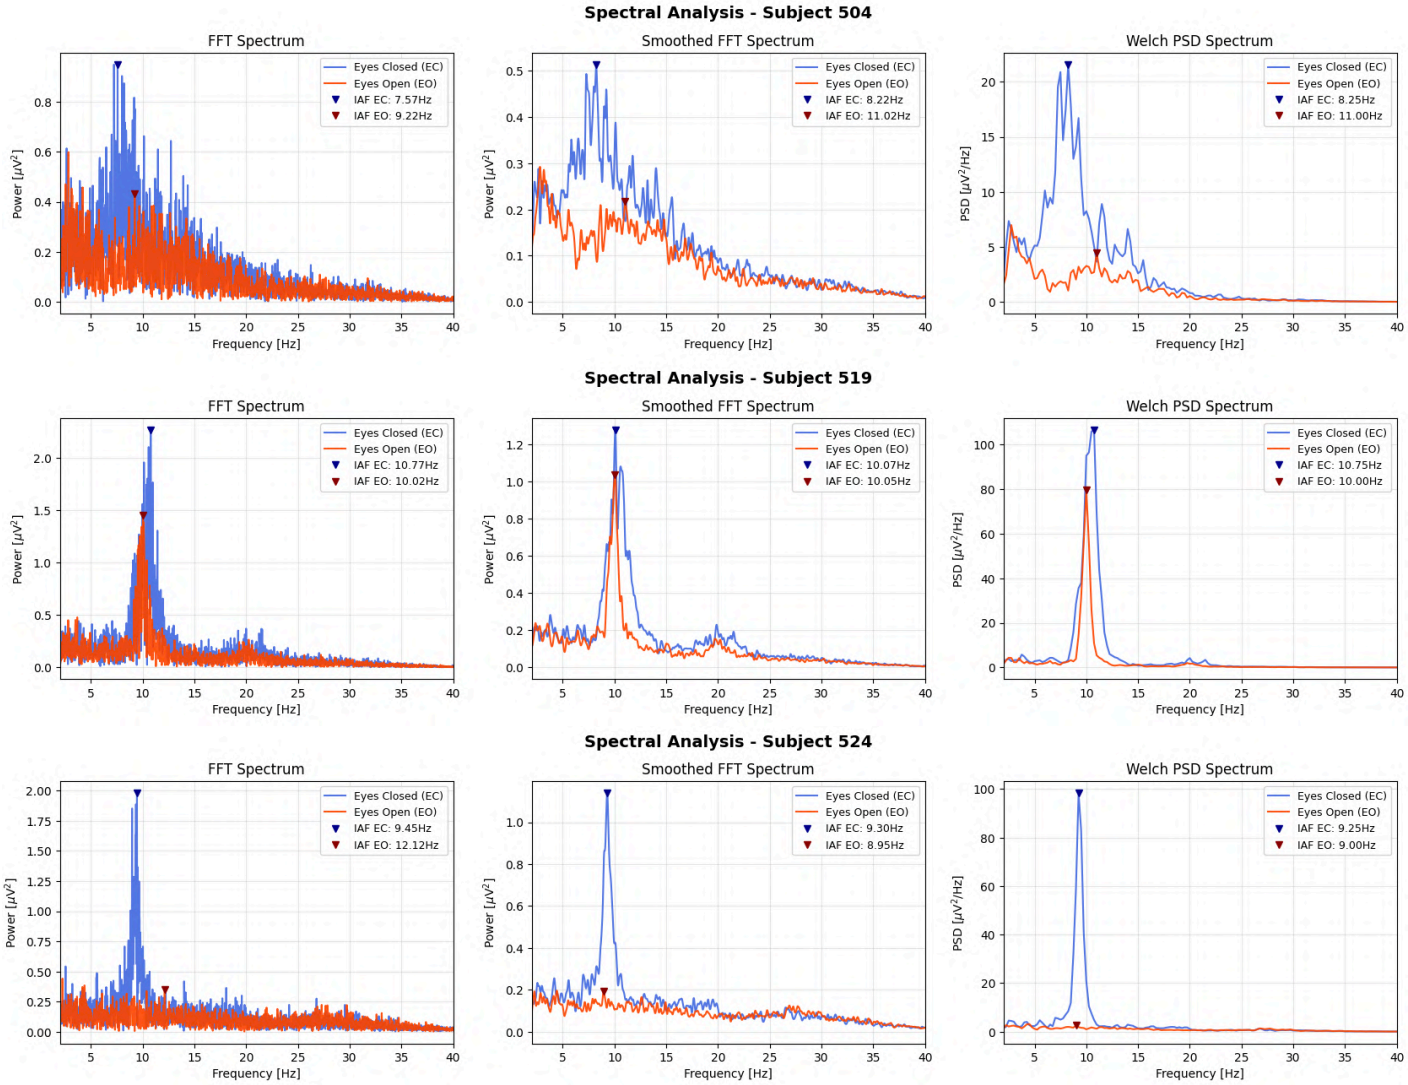
4. בסעיף זה יצרתי פונקציה שתפקידה לאתר את תדר האלפא האינדיבידואלי (IAF) של כל נבדק מתוך ספקטרום התדרים.
ראשית, הגדרתי את טווח התדרים להיות בין 7.5Hz לבין 12.5Hz (טווח האלפא הקלאסי). מתוך טווח התדרים הזה השתמשתי בפונקציה np.argmax כדי לאתר את האינדקס שבו מופיע תדר השיא, וחילצתי את התדר התואם לאינדקס זה.
לאחר מכן, קראתי לפונקציה על כל 3 הערכות הספקטרום שחושבו בסעיפים הקודמים, ושמרתי את תדרי ה-IAF שהתקבלו עבור כל נבדק, תוך הפרדה בין מצב עיניים סגורות (EC) למצב עיניים פקוחות (EO), ולהלן התוצאות:

Participant	Condition	Raw FFT [Hz]	Smoothed FFT [Hz]	Welch PSD [Hz]
504	EO	9.22	11.02	11.00
504	EC	7.57	8.22	8.25
519	EO	10.02	10.05	10.00
519	EC	10.77	10.07	10.75
524	EO	12.12	8.95	9.00
524	EC	9.45	9.30	9.25

```python
def find_iaf(freqs, power):
    """
    Finds the peak alpha frequency and its maximum power in the 7.5–12.5 Hz range.
    """
    alpha_mask = (freqs >= 7.5) & (freqs <= 12.5)
    alpha_freqs = freqs[alpha_mask]
    alpha_power = power[alpha_mask]

    max_idx = np.argmax(alpha_power)
    return alpha_freqs[max_idx], alpha_power[max_idx]
```

<u>גרפים:</u>
בגרפים הבאים ניתן לראות את ה-Power Spectrum עבור כל נבדק, המחושב בשלוש שיטות: FFT גולמי, FFT מוחלק, וממוצע Welch. הגרפים מציגים את התפלגות ההספק בתדרים השונים עבור המצבים EC ו-EO, וכוללים סימון המצביע על ה-IAF ברצועת האלפא.



<u>דיון:</u>

ההבדלים בין השיטות הספקטרליות (FFT, Smoothed FFT, Welch PSD):

ניתוח האותות באמצעות שלוש השיטות מדגים את הטרייד-אוף (Trade-off) בין רזולוציית תדר לעמידות בפני רעש.
ספקטרום ה-FFT הגולמי מציג אמנם רזולוציית תדר מקסימלית, אך הוא רועש מאוד ו"קוצני" עקב רגישות גבוהה לתנודות מקומיות, מה שמקשה על זיהוי מגמות בספקטרום.
לעומתו, שיטת ה-Smoothed FFT פותרת בעיה זו על ידי החלקה מתמטית גאוסיאנית שמנקה את רעשי הרקע הנקודתיים, וכל זאת תוך שמירה מלאה על רזולוציית התדר המקורית ועל קווי המתאר הכלליים של ה-FFT הגולמי.
מנגד, שיטת Welch מייצרת את הספקטרום החלק והיציב ביותר מבין השלוש על ידי חלוקה של האות המלא למקטעי זמן קצרים וחופפים, עליהם מופעל חלון Hann, ומיצוע שלהם. עם זאת, שיטה זו גורמת להקטנה ניכרת של רזולוציית התדר, מה שמוביל את הספקטרום להיראות רחב ופחות מדויק נקודתית בהשוואה לשיטות האחרות.

נראות וחדות פיק האלפא:

פעולות ההחלקה והמיצוע משפיעות ישירות על היכולת לזהות את הפעילות האוסצילטורית הדומיננטית באופן אמין.
בספקטרום ה-FFT הגולמי, טווח האלפא מכיל מספר "קוצים" צפופים המקשים על האלגוריתם לאתר את נקודת השיא המדויקת, שכן קיים סיכוי לא קטן לבחירת רעש מקומי אקראי כנקודת הקיצון.
החלקת ה-FFT פותרת בעיה זו באופן חלקי על ידי איחוד הקוצים הרועשים הללו לגבעה אחת חדה וברורה, מה שמאפשר זיהוי קל, מדויק ויציב של שיא האלפא. מנגד, חלון החלקה רחב מדי עלול למרוח או להנמיך מעט את גובה השיא.
בשיטת Welch, הפיק נראה אמנם ברור לחלוטין ונטול רעשים, אך בשל אובדן רזולוציית התדר כתוצאה מפעולת המיצוע, הפסגה נוטה להיות שטוחה ופחוסה יותר, עובדה המקשה על בידוד התדר המדויק ברמת חלקיקי ההרץ.

ההבדלים בין מצב עיניים פקוחות (EO) לסגורות (EC):

בכל השיטות הניתוחיות שהוצגו כאן עולים הבדלים משמעותיים בין שני התנאים, וניתן לראות עקביות בהבדלים אלו בין על הנבדקים.
ההשוואה מדגימה בצורה מובהקת את תופעת חסימת האלפא (Alpha Blocking).
במצב בו העיניים סגורות (EC), קליפת המוח הראייתית (בפרט, נוירונים הנמצאים תחת אלקטרודת POz) נמצאת במצב "מנוחה", תופעה המתבטאת בירי פעימתי וסינכרוני של נוירונים אלו המייצר פיק עוצמתי וברור מאוד בטווח התדרים של 8-12 הרץ.
עם פקיחת העיניים (EO), המוח עובר באופן מיידי לעיבוד מידע חזותי פעיל, מה שגורם לנוירונים באזורי הראייה האחוריים לצאת מסינכרון ולעוצמת האלפא להיות מדוכאת כמעט לחלוטין. אכן, מגמה מובהקת זו של ירידה דרסטית בעוצמת (Power) גלי האלפא במעבר ממצב מנוחה לעוררות חזותית נצפתה באופן עקבי ודומה אצל כלל הנבדקים בניסוי.

הבדלים אינדיבידואליים בין המשתתפים:

על אף שהמגמה הכללית של דיכוי אלפא בעת פקיחת עיניים נשמרת באופן עקבי אצל כולם, ניכר שוני ברור בפרופיל הספקטרלי בין הנבדקים השונים, הן בערך המדויק של תדר ה-IAF (למשל, נבדק אחד עם שיא ב-8.25Hz ואחר ב-10.75Hz במצב EC) והן בעוצמתו המוחלטת (האמפליטודה).
הבדלים אלו עשויים לנבוע ממגוון רחב של גורמים, כגון הבדלים אנטומיים (כמו למשל עובי הגולגולת המשפיע על הנחתת האות החשמלי בדרכו לאלקטרודה, או במבנה הקיפול הקורטיקלי), הבדלים גנטיים, או שונות טבעית ברמת העוררות המנטלית והקשב הספציפית של כל נבדק בזמן ביצוע הניסוי.
שונות בין-אישית זו מצביעה על כך שפעילות מוחית אוסצילטורית אינה אחידה בין בני אדם, אלא משמשת כמעין "טביעת אצבע" אינדיבידואלית, וכן מדגישה את החשיבות של שימוש במדדים מותאמים אישית כמו ערך IAF במקום בטווח תדרים קבוע ומוגדר מראש.

הערכת תדרי ה-IAF:

מבין כלל השיטות שנידונו, ניכר כי ההערכה האמינה והיציבה ביותר של תדר ה-IAF מתקבלת מתוך ספקטרום ה-Welch PSD במצב עיניים סגורות (EC).
ראשית, מצב ה-EC מספק את יחס האות-לרעש (SNR) הגבוה ביותר עבור פעילות אלפא טבעית, מה שמונע זיהוי שגוי של רעשים אקראיים כפי שעלול להתרחש במצב ה-EO שבו האלפא מדוכאת. שנית, היתרון המובהק של שיטת Welch טמון ביכולתה לפתור את בעיית השונות הגבוהה המאפיינת סיגנלים רועשים. על ידי חלוקת האות לפרקי זמן קצרים וביצוע מיצוע של הספקטרומים שלהם, השיטה למעשה "מנקה" רעשים מקומיים וארטיפקטים חולפים, ומבליטה אך ורק את הפעילות המחזורית והעקבית ביותר, בניגוד לשתי השיטות האחרות שעשויות להציג תנודות או ערכים המושפעים מרעש נקודתי.
למרות שתהליך המיצוע מקריב במידת מה את רזולוציית התדר בהשוואה ל-FFT הגולמי, היציבות הסטטיסטית שהוא מספק מבטיחה שפיק האלפא שנבחר אינו תוצר של תנודה נקודתית מקרית, אלא משקף בצורה האמינה ביותר את התכונה הפיזיולוגית האמיתית של הנבדק.

חלק 4: Spectrogram

1. בסעיף זה חישבתי ספקטרוגרמה לכל נבדק בשני התנאים (EC ו-EO) באמצעות הפונקציה spectrogram. תחילה הגדרתי חלון של 2 שניות וחפיפה של 90%, והמרתי ערכים אלו למספר דגימות על ידי הכפלתם בתדר הדגימה (fs). לאחר מכן, הפעלתי את הפונקציה על האות המסונן תוך שימוש בחלון 'Hann' למניעת זליגת תדרים בקצוות. התוצאות שהתקבלו - מערכי זמנים, תדרים ומטריצת צפיפות הספק (PSD) - נשמרו במילון הנתונים שלנו. את ערכי ההספק המרתי מסולם ליניארי לסולם לוגריתמי של דציבלים (dB) על מנת להבליט את הפערים.

```
from scipy.signal import spectrogram

# Defining parameters.
SPEC_WINDOW_SEC = 2
SPEC_OVERLAP_RATIO = 0.90

for sub in subjects:
    ec_sig = data[sub]['EC_filtered']
    eo_sig = data[sub]['EO_filtered']

    # Calculating the number of samples per wundow and overlap.
    nperseg_spec = int(SPEC_WINDOW_SEC * fs)
    noverlap_spec = int(nperseg_spec * SPEC_OVERLAP_RATIO)

    # Calculating the spectrogram.
    f_ec, t_ec, Sxx_ec = spectrogram(ec_sig, fs, window='hann', nperseg=nperseg_spec, noverlap=noverlap_spec)
    f_eo, t_eo, Sxx_eo = spectrogram(eo_sig, fs, window='hann', nperseg=nperseg_spec, noverlap=noverlap_spec)

    # Converting to dB.
    Sxx_ec_dB = 10 * np.log10(Sxx_ec + 1e-10)
    Sxx_eo_dB = 10 * np.log10(Sxx_eo + 1e-10)

    # Saving the results for plotting.
    data[sub]['Spec_f_EC'], data[sub]['Spec_t_EC'], data[sub]['Spec_Sxx_dB_EC'] = f_ec, t_ec, Sxx_ec_dB
    data[sub]['Spec_f_EO'], data[sub]['Spec_t_EO'], data[sub]['Spec_Sxx_dB_EO'] = f_eo, t_eo, Sxx_eo_dB

print("Spectrogram calculations completed.")
```

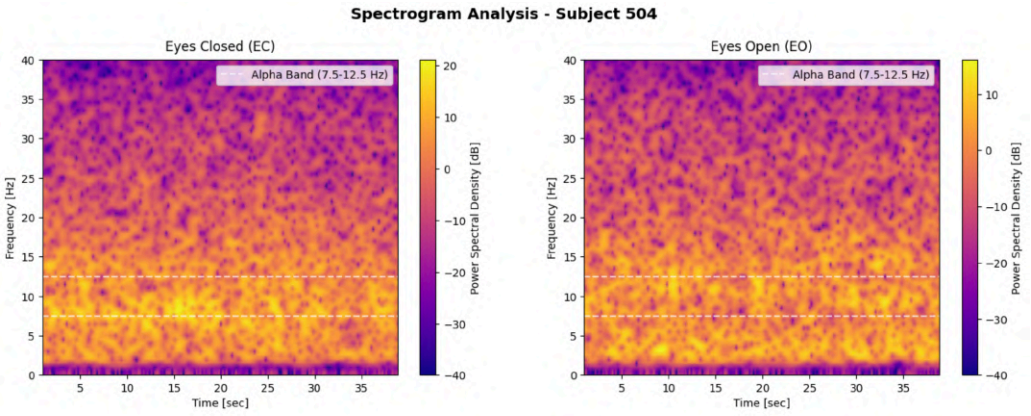
2. נסביר מהי המשמעות של ספקטוגרמה, וכן נעמוד על ההבדלים בינה לבין ספקטרום הספק:

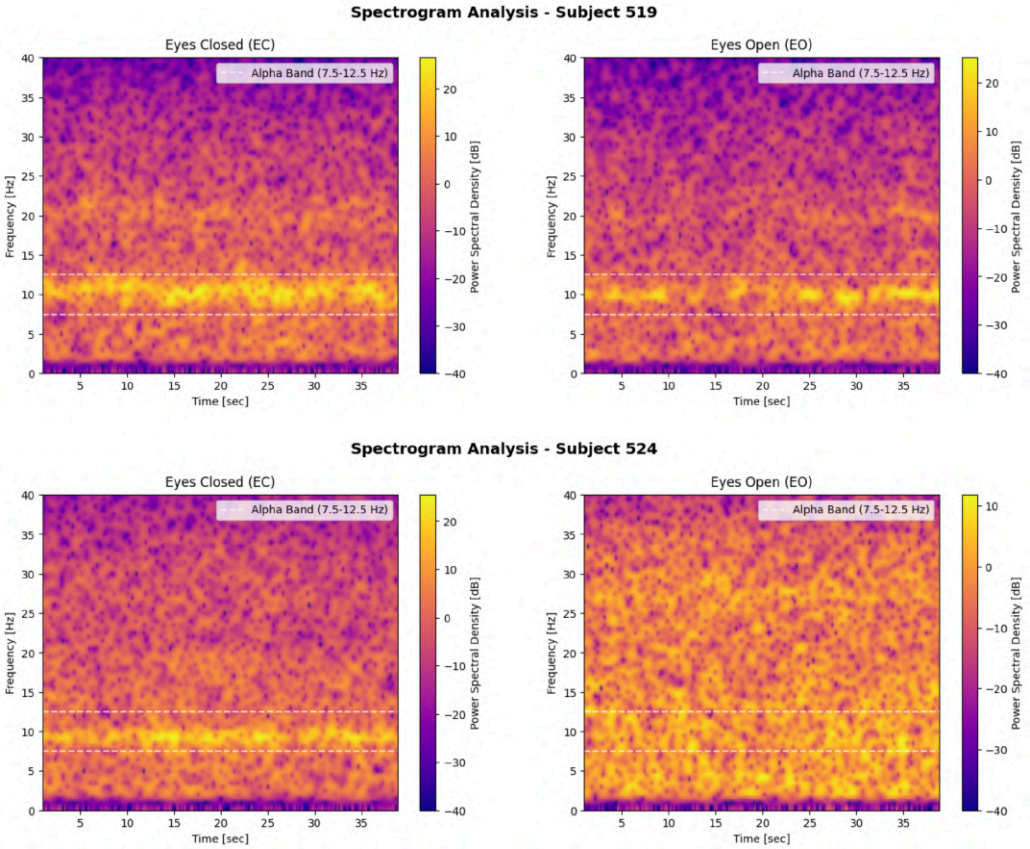
- ספקטרוגרמה היא ייצוג ויזואלי דו-ממדי (Time-Frequency Representation) של שינויי עוצמת התדרים באות לאורך זמן. בגרף זה, ציר ה-X מייצג את הזמן (בשניות), ציר ה-Y מייצג את התדרים (בהרץ), ועוצמת האות (Power) בנקודה ספציפית מיוצגת על ידי מפת צבעים (Heatmap), כאשר צבעים בהירים (כמו צהוב) מעידים על עוצמה גבוהה, וצבעים כהים (כמו סגול כהה) מעידים על עוצמה נמוכה.
- Power Spectrum מציג ממוצע סטטי של עוצמת התדרים על פני כל ההקלטה (40 שניות) ולמעשה "מוחק" את ממד הזמן. כלומר, הוא מראה לנו <u>אילו</u> תדרים נוכחים באות, אך לא מפאשר לנו לראות <u>מתי</u> הם הופיעו. לעומת זאת, הספקטרוגרמה מאפשרת לנו לראות בדיוק *מתי* התרחשה פעילות (הגברה או החלשה) בתדר מסוים.

3. חישוב הספקטרוגרמה דורש חלוקה של האות למקטעי זמן קצרים, והפרמטרים בקוד נבחרו בקפידה כדי לייצר איזון אופטימלי בין רזולוציית זמן לרזולוציית תדר.

- <u>אורך החלון:</u> בחרתי בחלון זמן באורך של 2 שניות (SPEC_WINDOW_SEC = 2). חלון זה ארוך מספיק כדי לספק רזולוציית תדר טובה של 0.5Hz, הנדרשת לאיתור מדויק של רצועת האלפא, אך קצר מספיק כדי לאפשר לנו לעקוב אחר שינויים מהירים בזמן.
- <u>חפיפה:</u> בחרתי באחוז חפיפה גבוה של 90% בין החלונות (SPEC_OVERLAP_RATIO = 0.90). חפיפה קיצונית זו, בשילוב עם חלון מסוג Hann המונע זליגת תדרים בקצוות, גורמת לכך שהחלון ינוע בצעדים קטנים מאוד לאורך האות ומבטיחה מעבר חלק ורציף לחלוטין של מפת הצבעים על פני ציר הזמן. כתוצאה מכך היא מונעת איבוד מידע של "בלוקים" או קפיצות חדות בגרף.

4. הגרפים המובאים כאן מציגים עבור כל נבדק את הספקטרוגרמה עבור מצב EO ו-EC, כאשר ציר X הוא הזמן, ציר Y הוא התדירות, והצבע מייצג את ההספק. בנוסף מסומן החלק של רצועת האלפא (7.5-12.5Hz) על מנת להקל על מציאתם.





5. התבוננות בספקטרוגרמות של מצב עיניים סגורות (EC) מגלה שפעילות האלפא (הנראית כפס צהוב בוהק בטווח שבין 7.5 ל-12.5 הרץ) אינה אות רציף וקבוע בעוצמתו. במקום זאת, ניתן לראות שהיא מופיעה בתבנית של התפרצויות קצרות (Spindles) - שנראות כמו "כתמים" צהובים בוהקים שמופיעים למספר שניות ונעלמים.
יתרה מכך, ההשוואה למצב עיניים פקוחות (EO) ממחישה את תופעת ה-Alpha Blocking בזמן אמת לאורך כל ההקלטה. הפס הצהוב הבוהק נעלם כמעט לחלוטין ומוחלף בפעילות רקע אקראית אצל נבדקים 504 ו-524. גם אצל נבדק 519, המציג שאריות אלפא במצב EO, ניתן לראות בספקטרוגרמה שהפעילות הרבה יותר מקוטעת וחלשה משמעותית בהשוואה למצב המנוחה שלו.

חלק 5: *Alpha Reconstruction Using IFFT*

בסעיפים 1-4 בניתי את הפונקציה recons_alpha המבצעת שחזור של גלי האלפא מתוך אות ה-EEG המקורי באמצעות התמרת פורייה הפוכה (IFFT).
תחילה, הפונקציה מפעילה התמרת פורייה מהירה (np.fft.rfft) כדי להעביר את האות המסונן ממרחב הזמן למרחב התדר, ומגדירה מסכה לוגית המבודדת את רצועת האלפא האישית של הנבדק בטווח של IAF ± 1Hz.
לאחר מכן, הקוד מעתיק את ערכי ה-FFT, מאפס לחלוטין את כל התדרים שמחוץ לטווח המבודד (קביעתם כ-0), תוך שמירה על תדרים חיוביים ושליליים כאחד (באמצעות שימוש בערך המוחלט של התדר). השמירה על הסימטריה של התדרים השליליים היא קריטית כדי להבטיח שהאות המשוחזר יהיה ממשי.
לבסוף, הרצתי את הפונקציה np.fft.irfft שמחזירה את האות המנוקה והמבודד בחזרה לציר הזמן, וחילצתי את החלק הממשי שלו.

```python
def recons_alpha(signal, fs, iaf_freq):
    """
    Reconstructs the alpha band signal using Inverse FFT.
    Keeps only the frequencies within IAF +/- 1 Hz and sets the rest to zero.
    """
    N = len(signal)

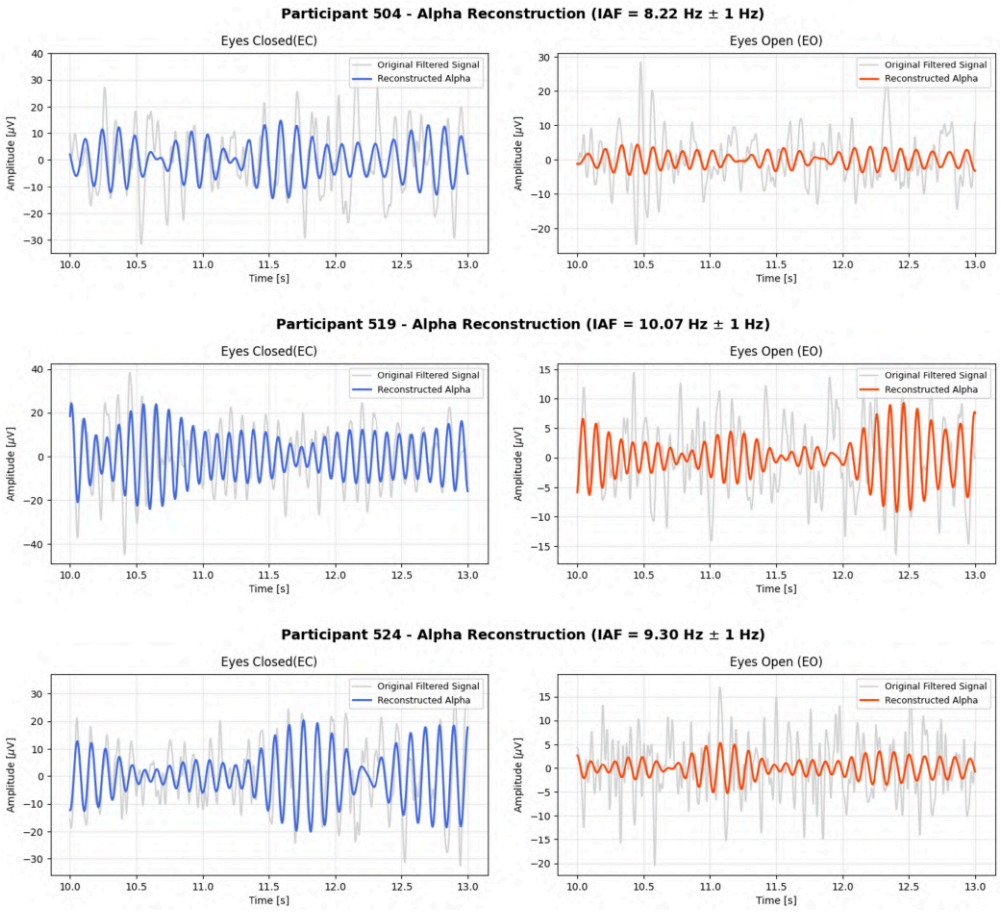
    # Compute the FFT of the signal.
    freqs = np.fft.rfftfreq(N, 1/fs)
    fft_vals = np.fft.rfft(signal)

    # Define an individual alpha band (IAF +/- 1 Hz).
    lower_bound = iaf_freq - 1.0
    upper_bound = iaf_freq + 1.0
    alpha_mask = (np.abs(freqs) >= lower_bound) & (np.abs(freqs) <= upper_bound)

    # Keep only frequencies within this range, set others to zero.
    fft_filtered = np.copy(fft_vals)
    fft_filtered[~alpha_mask] = 0

    # Reconstruct the signal using IFFT.
    recons_signal = np.fft.irfft(fft_filtered, n=N).real
    return recons_signal
```

5. הגרפים הבאים מציגים שחזור של אות האלפא במרחב הזמן כאשר הוא מוטל על גבי אות ה-EEG המקורי, עבור כל משתתף וכל מצב. לצורך הדגשת התוצאות והצגתן בצורה הברורה ביותר, נבחר חלון זמן של 3 שניות (שניות 10-13 בסיגנל).



6. התבוננות באות האלפא המשוחזר בהשוואה לאות ה-EEG המקורי חושפת שינוי ויזואלי משמעותי במראה האות. בעוד שהאות המקורי מתאפיין במבנה מורכב, משונן ולא סדיר הנובע משילוב של תדרים רבים ורעשי רקע, האות המשוחזר נראה כגל חלק, מחזורי וסינוסואידלי.
תהליך בידוד רצועת האלפא האינדיבידואלית ואיפוס שאר הרכיבים הסיר את כל המידע הרעשני שהיה בתדרים הגבוהים ואת התנודות האיטיות של תדרי הרקע הנמוכים. המידע היחיד שנשמר בתהליך השחזור הוא האמפליטודה (העוצמה) והפאזה של הנוירונים הפועלים בתדר האלפא.
ניתן לראות בבירור בגרפים כי הגל המשוחזר מתלכד עם נקודות השיא והשפל הריתמיות הכלליות של האות המקורי, מה שמוביח שחזור אמין של תזמון הפעילות המוחית בזמן אמת.
בנוסף, ההבדלים הפיזיולוגיים בין תנאי עיניים סגורות (EC) לעיניים פקוחות (EO) באים לידי ביטוי באות המשוחזר:
במצב עיניים סגורות (EC), האות המשוחזר מתאפיין בתנודות רציפות באמפליטודה גבוהה, דבר המשקף את הסינכרוניזציה הגבוהה של גלי האלפא במצב מנוחה.
לעומת זאת, במצב עיניים פקוחות (EO), שבו פעילות האלפא מדוכאת עקב מעבר לעיבוד חזותי אקטיבי, האות המשוחזר קטן בצורה דרסטית והופך כמעט שטוח לחלוטין.
ממצא זה מדגים בצורה חזותית מובהקת כי למרות שהאות המקורי במצב EO עדיין נראה תנודתי ומלא פעילות (הנובעת מתדרים אחרים ומרעשי שרירים), פעילות האלפא הפיזיולוגית עצמה כמעט ואינה קיימת בו, ותהליך השחזור הצליח לבודד ולהראות זאת בצורה נקייה.